

doi:10.3969/j.issn.1674-2257.2011.04.003

· 中药品质研究专题 ·

高效液相色谱法结合支持向量机鉴别桑白皮

杨文字^{1,2}, 游元元³, 万德光²

(1. 西华大学生物工程学院, 成都 610039; 2. 成都中医药大学药学院, 成都 610075; 3. 成都医学院药学院, 成都 610083)

【摘要】 目的 建立一种区分基原为 *Morus alba* L. 和非 *M. alba* L. 的中药桑白皮的可靠鉴别方法。**方法** 以桑白皮乙醚部位高效液相色谱(high performance liquid chromatography, HPLC)法色谱峰的归一化数据作为输入向量, 随机分为训练样本和测试样本, 用支持向量机软件构造区分不同基原样本数据的分类超平面以建立分类模型, 并将分类结果与相似度分析法相比较。**结果** 相似度分析法未能对某些桑白皮样本是否属于 *M. alba* L. 给出准确判断。支持向量机方法所建分类模型, 对样本属于 *M. alba* L. 与否的预测准确度达到 100%。**结论** 高效液相色谱法结合支持向量机能够准确鉴别桑白皮的基原属性, 在中药鉴别领域有广阔的应用空间。

【关键词】 桑白皮; 鉴别; 高效液相色谱法; 支持向量机; 相似度

【中图分类号】 R282.5 **【文献标志码】** A **【文章编号】** 1674-2257(2011)04-0287-04

Identification of Sang-Bai-Pi (Cortex Mori Albae Radicis) by combined high performance liquid chromatography and Support Vector Machine Method

YANG Wen-yu^{1,2}, YOU Yuan-yuan³, WAN De-guang²

(1. School of bioengineering, Xihua University, Chengdu Sichuan, 610039, China; 2. School of pharmacy, Chengdu University of Traditional Chinese Medicine, Chengdu Sichuan, 610075, China; 3. School of Pharmaceutical Sciences, Chengdu Medical College, Chengdu Sichuan, 610083, China)

【Abstract】 Objective To develop a reliable method for recognizing Cortex Mori Radicis (CMR) samples originated from *Morus alba* L. or not. **Methods** Using normalized high performance liquid chromatography (HPLC) peak areas of CMR ether extracts as modeling data, and using two randomly divided sample-sets as training data and testing data, the optimal separating hyperplane of two datasets and the classification model were constructed by support vector machine (SVM) software. For comparative purpose, the similarity of HPLC profiles was calculated using vectorial angle method. **Results** Confirmation of *M. alba* origin of above CMR samples was partly missed in similarity analysis, while the predicted classification accuracy of those samples reached 100% when using SVM classification model. **Conclusion** Combined HPLC and SVM method can correctly recognize the original plant features of Sang-Bai-Pi, and can be easily generalized to identify more other Chinese medicinal materials.

【Key words】 Sang-Bai-Pi (Cortex Mori Albae Radicis); identification; HPLC; support vector machine; similarity

《中国药典》所载的桑白皮为桑科植物桑 *Morus alba* L. 的已除去外层粗皮的干燥根皮^[1], 但市场上其同属植物较多, 如鲁桑 *M. alba* var. *multicaulis*、蒙桑 *M. mongolica*、华桑 *M. cathayana* 等^[2,3]。目前桑白皮的鉴别主要依靠性状鉴别和薄层鉴别^[1], 但由于鉴别特征不甚明显, 往往难以准确判断药材样品是否源于 *M. alba* L.。高效液相色谱 (high performance liquid chromatography, HPLC) 法能够通过其给

出的非线性、高维度的色谱峰指纹信息来综合判断样品的属性, 是一种鉴别中药的较好方法; 但实验表明, 由于桑白皮药材特征因种质、产地等因素而有较大变化, 基于计算 HPLC 相似度的判别方法对某些桑白皮样品的鉴别并不完全适用, 有必要采用更好的数学分类方法以提高鉴别能力。支持向量机是一种非常适合非线性、高维度、小样本数据分类的新方法^[4-6], 其原理是根据各样本的属性, 对于给定的样本复杂数据 (即多维向量) 构造一种决策函数, 该函数能够建立不同属性样本之间的分类超平面并使之尽可能大, 类似于找到同一平面内多个不同颜色的点之间的最大分类界面。同一基原药材的 HPLC 色谱峰之间的关系应当存在一定规律, 这一

基金项目 国家自然科学基金项目 (30672625); 四川省教育厅科研基金项目 (10ZC057)

通讯作者 万德光, E-mail: wandeguag@163.com

规律可能正好是与源于同属其他基原药材的重要区别点。理论上将反映桑白皮 HPLC 色谱峰之间相互关系的数据作为输入向量,用支持向量机方法寻找分类界面,应当能够准确鉴别桑白皮药材的基原。基于该推论,我们对此进行了探讨。现将结果报道如下。

1 材料与方法

1.1 试验材料与仪器

1.1.1 试剂与仪器 乙腈(色谱纯,美国 Fisher 公司);甲醇、乙醇、石油醚(60~90 ℃)、乙醚、磷酸均为分析纯,成都科龙化工厂产品;水为超纯水。

Dionex P680 型 HPLC 仪(美国戴安公司);P680 泵、UV D170U 紫外检测器、TCC-100 柱温箱、ASI-100 自动进样器、Chromeleon 色谱工作站。BP 1215 电子天平(德国赛多利斯公司,d=0.1 mg),Rios 纯水器(密理博上海贸易有限公司),

AS5150BD-I 超声波清洗器(天津奥特赛恩斯仪器有限公司)。

1.1.2 药材 共收集 11 批桑白皮药材(表 1),参照文献[7]的方法鉴定种质不清的药材。表中几种杂交桑的基原:嘉陵 16 号为西庆一号×育二号,西庆一号为引自日本的四倍体桑树,基原不详,育二号为湖桑 39 号(*M. alba* var. *multicaulis*)×广东荆桑(*M. atropurpurea*);湘 7920 为中桑 5801 号×澧桑 24 号(*M. alba* var. *multicaulis*),中桑 5801 号为湖桑 38 号(*M. alba* var. *multicaulis*)×广东荆桑(*M. atropurpurea*)。嘉陵 20 号为湘 7920×西庆四号,西庆四号为桐乡青(*M. alba* var. *multicaulis*)经秋水仙碱诱变所得的四倍体植株。广东荆桑 *M. atropurpurea* 在《中国植物志》[8]中已被合并于 *M. alba* 之中。

表 1 桑白皮药材样品的来源

Tab. 1 Original plants of Cortex Mori Radicis samples

药材代号	来源	基原	种质	备注
A1	成都市犀浦镇老国药店	<i>M. alba</i> L.	-	参照文献[7]的方法鉴定
A2	四川遂宁市永兴镇(栽培)	<i>M. alba</i> L. (<i>M. atropurpurea</i> Roxb.)	广东荆桑	当地蚕桑站认定种质
安县	四川安县花荪镇(栽培)	杂交桑	嘉陵 16 号	当地蚕桑站认定种质
汉中	陕西汉中市汉台区(栽培)	<i>M. alba</i> L.	陕桑 305	当地蚕桑站认定种质
河北	河北安国中药材专业市场	<i>M. alba</i> L.	-	参照文献[7]的方法鉴定
荷花池	成都市荷花池中药材专业市场	<i>M. mongolica</i> Schneid	-	参照文献[7]的方法鉴定
湖南	湖南澧县澧阳镇(栽培)	杂交桑	湘 7920	当地蚕桑站认定种质
凯里	贵州凯里市郊(野生)	<i>M. australis</i> Poir.	-	参照《中国植物志》鉴定
内江	四川内江市永福乡(栽培)	杂交桑	湘 7920	当地蚕桑站认定种质
潼南	重庆市潼南县上和镇(栽培)	杂交桑	嘉陵 20 号	当地蚕桑站认定种质
新疆	新疆医科大学附属医院	<i>M. alba</i> L.	-	参照文献[7]的方法鉴定

1.1.3 软件 支持向量机软件 Libsvm 2.85(台湾大学林智仁博士提供,http://www.csie.ntu.edu.tw/~cjlin/libsvm/),脚本执行程序 Python 2.5(自由软件,http://www.python.org/),数学绘图软件 Gnuplot 4.0(自由软件,http://www.gnuplot.info/)。上述软件均运行在 Microsoft Windows XP Professional 操作系统上。

1.2 供试品溶液的制备

取粉碎后的药材 10 g,用乙醇回流提取,提取液回收乙醇后,悬浮于水中,用等体积石油醚萃取 3 次,弃去石油醚,换用等体积乙醚萃取 3 次,合并乙醚萃取液,回收乙醚,残渣用甲醇超声溶解,转移至 100 mL 量瓶中并稀释至刻度,取 1.0 mL,置 10 mL 量瓶中,用乙腈稀释至刻度,作为供试品溶液。

1.3 色谱条件

色谱柱:Phenomenex Luna C18(2)(250 mm×4.6 mm, 5 μm);流动相:乙腈(A)-0.5%磷酸(B);洗脱方式:梯度洗脱,梯度程序见表 2。流速:0.8 mL/min;检测波长:320 nm;柱温:25 ℃。进样量:10 μL。

1.4 色谱峰的积分与预处理

设定各药材 HPLC 图谱中色谱峰积分的阈值为 5.0(信噪比约为 10/1),全部采用手动积分以避免色谱工作站自动

表 2 流动相梯度程序

Tab. 2 The gradient elution scheme

时间(min)	0	10	25	35	55	75	85	105
A(v/v)%	10	15	25	34	46.5	59.5	67	80
B(v/v)%	90	85	75	66	53.5	40.5	33	20

积分时默认参数导致的积分误差。采用色谱峰积分值原始数据计算药材相似度。在进行支持向量机分类时,以各样本 HPLC 图谱中峰面积最大者为参照峰,计算其图中各峰与参照峰的比值,将所得数据用作支持向量机分类器的输入值。

1.5 相似度的计算

采用向量夹角余弦法[9]计算各药材 HPLC 图谱的两两相似度:将药材 A 的各色谱峰面积作为 n 维向量($x_1, x_2, \dots, x_n$),药材 B 的各色谱峰面积作为 n 维向量($y_1, y_2, \dots, y_n$),则 A 与 B 的相似性可用二者在几何空间的向量夹角 θ 的余弦

来度量: $\cos\theta = (\sum_{i=1}^n x_i y_i) / \sqrt{\sum_{i=1}^n x_i^2 \cdot \sum_{i=1}^n y_i^2}$ 。cos θ 越接近 1,则 A 与 B 的相似性越大。

1.6 支持向量机分类的处理方法

设定源于 *M. alba* 的药材 HPLC 色谱峰面积数据集样本的分类属性为 1,非 *M. alba* 的样本的分类属性为-1。上述药材样本共 11 个,将属于 *M. alba* 的 5 个药材样本的 HPLC 图谱分别两两相加(相加结果相当于两药材供试品溶

液混合后再进样分析的结果),得到另 10 个属于 *M. alba* 的样本;将属于非 *M. alba* 的 6 个药材样本的 HPLC 图谱分别两两相加,得到另 15 个属于非 *M. alba* 的样本。总样本量为 36 个,随机选择 25 个样本作为支持向量机训练样本,另 11 个样本作为测试样本。

用 Libsvm 软件对训练样本的输入值进行机器学习,通过径向基核函数构造分类决策函数从而建立分类模型;在此过程中,采用网格搜寻和交叉验证方法搜索径向基核函数的重要参数,即最优值即惩罚因子 c 和径向基系数 γ ,用

Gnuplot 软件绘制交叉验证精度等高线 $[\lg(c)-\lg(\gamma)]$ 以使参数寻优过程直观化。用该模型预测各测试样本的分类属性,判断其为 1 还是-1。具体运算时用 Python 软件在命令行调用 Libsvm 和 Gnuplot 程序。

2 结果与分析

2.1 HPLC 图谱

11 批桑白皮药材乙醚部位的 HPLC 图谱总体上具有一定的相互相似性(图 1),这应当与它们均源于 *Morus L.* 属有关,但药材之间的差异也很明显。




图 1 11 批桑白皮药材乙醚部位 HPLC 图谱

Fig. 1 HPLC chromatograms of 11 ether extract samples of Cortex Mori Radicis

表 3 11 批桑白皮药材乙醚部位 HPLC 图谱的两两相似度

Tab. 3 The pairwise similarities of HPLC profiles of 11 ether extract samples of Cortex Mori Radicis

相似度	A1	A2	安县	汉中	河北	荷花池	湖南	凯里	内江	潼南	新疆
A1	1										
A2	0.934	1									
安县	0.726	0.751	1								
汉中	0.947	0.967	0.815	1							
河北	0.945	0.96	0.703	0.96	1						
荷花池	0.879	0.915	0.853	0.956	0.865	1					
湖南	0.949	0.968	0.768	0.99	0.971	0.936	1				
凯里	0.552	0.571	0.837	0.607	0.556	0.634	0.565	1			
内江	0.813	0.834	0.827	0.876	0.813	0.888	0.876	0.626	1		
潼南	0.866	0.894	0.874	0.927	0.859	0.929	0.91	0.716	0.861	1	
新疆	0.519	0.551	0.701	0.618	0.438	0.759	0.587	0.494	0.665	0.682	1

2.2 药材两两相似度

11 批桑白皮药材乙醚部位的 HPLC 图谱的两两相似度见表 3。可以看出,源于 *M. alba* L. 的 5 批药材中,除新疆样本与其他药材样本相似度较小外,另 4 个药材样本的两两相似性均在 90% 以上。但非 *M. alba* L. 的药材样本也有一些与源于 *M. alba* L. 的药材的相似性较高,如荷花池样本与 A2 样本、湖南样本与 A1 样本、潼南样本与汉中样本等的相似度均高于 90%。因此,通过相似度分析并不能完全、准确

地判断桑白皮药材是否来源于 *M. alba* L.。

2.3 支持向量机分类结果

参数寻优过程的交叉验证精度等高线见图 2。图中各曲线反映 c 和 γ 取不同值时,所建立的支持向量机分类模型的准确程度。本实验数据用于支持向量机分类,其交叉验证精度在 97%~100% 范围内,这表明,对于根据 HPLC 数据判断桑白皮是否属于 *M. alba* L. 这一目的,用支持向量机方法建立分类模型是非常适宜的。支持向量机运算过程和结

果见图 3, 参数 c 的最优值为 2.0、参数 $\gamma(\text{gamma}, g)$ 的最优值为 0.0078125, 据此建立的支持向量机分类模型的交叉验证精度为 100%, 用此模型对 36 个总样本中 11 个测试样本进行预测, 结果对样本是否属于 *M. alba* L. 的预测准确率为 100%。上述 36 个总样本中, 随机重新挑选样本组成训练样本和测试样本, 并按上述方法建模和预测, 结果基本一致, 所建模型对测试样本均能达到 100% 的预测准确率。




图 2 参数寻优过程中的交叉验证精度等高线

Fig. 2 Contour of cross-validation accuracy during SVM parameters optimization




图 3 支持向量机分类的运算过程和结果

Fig. 3 Computing process and results of SVM classification

3 讨论

支持向量机方法是一种“黑箱”方法, 它只根据给定的样本数据, 即多维向量, 找出处于分类界面边缘的各个向量, 即支持向量, 并据此确定最佳的分类界面; 但并不给出产生这种分类的机理, 因此并不给出能涵盖样本集中每一数据的数学公式。因此, 该方法特别适合用于复杂性高而分类特征不明显的事物的分类, 而且, 这一特点使得其不仅适合大样本量数据的分类, 也能对小样本量的数据给出良好的分类结果, 这也是我们采用支持向量机方法分析桑白皮的 HPLC 数据的原因。另外, 支持向量机方法的样本集中, 增加或删除一些属于非支持向量的数据, 对分类模型不会产生影响,

因此, 该方法具有良好的鲁棒性。本研究结果表明, 用支持向量机方法, 对桑白皮乙醚部位的 HPLC 数据进行数学运算, 能够建立一种判断桑白皮是否属于 *M. alba* L. 的分类模型, 所建模型的预测准确率可达 100%。该方法的分类效果优于相似度方法。

本研究所选桑白皮 11 批药材的 HPLC 图谱中, 源于 *M. alba* L. 的 5 个药材图谱, 其所检出峰的数目、峰面积, 相互之间均有较大差异, 非 *M. alba* L. 药材图谱的情况也是这样, 而相似度计算结果也显示难以按基原区分药材, 说明直接比较峰数目和峰面积无法达到分类目的。在进行支持向量机分类时, 将各样本色谱峰进行归一化处理, 采用峰面积比值进行运算。峰面积比值反映了药材中各化学成分含量的相对关系, 据此用支持向量机方法建立的分类模型能达到 100% 的预测准确度, 即使对数据较为离群的新疆样本也能给出准确的预测, 表明同一基原样本的一些主要化学成分之间的含量相对关系存在着一定的内在规律。实验中按基原属性分别对样本 HPLC 图谱两两相加, 正是为了使这种内在规律更加明显, 从而有助于提高支持向量机模型的准确度。

市售桑白皮药材的基原植物和种质非常复杂^[7,10], 致使评价不同基原、不同种质和不同产地的桑白皮药材的品质变得十分困难。但根据中药品质“遗传主导论”和“环境修饰论”的理论^[11], 特定基原植物中药材必定具有其特定的内在品质; 而评价特定中药材的内在品质, 关键在于找到能充分揭示该中药材内在品质的方法。上述实验结果表明, 对于 HPLC 分析所表征的不同基原、不同种质和不同产地的桑白皮药材整体化学成分的特征属性, 按支持向量机原理进行分类, 是一种能准确揭示桑白皮 (*M. alba* L.) 药材内在品质的评价方法。本文结果为根据中药品质理论解决类似复杂问题提供了成功的范例。

参考文献

- [1] 国家药典委员会. 中国药典(2010 年版一部)[S]. 北京: 中国医药科技出版社, 2010: 280.
- [2] 李振国, 贾敏如. 川、黔产桑白皮的品种调查[J]. 中药材, 1991, 14(6): 23-24.
- [3] 杨德泉. 湖南桑白皮的原植物调查与鉴定[J]. 中药材, 1992, 15(8): 23.
- [4] Cortes C, Vapnik V. Support-vector networks[J]. Mach Learn, 1995, 20(3): 273-297.
- [5] Bradshaw D, Pensky M. Decision theory classification of high-dimensional vectors based on small samples[J]. Test, 2008, 17(1): 83-100.
- [6] Gu X, Yang SX, Qian SX, et al. Research on SVMs of small samples on rotary machine multiclass fault recognition[C]. Proc SPIE, 2006, 6357: 6357J.
- [7] 蔡少青. 常用中药材品种整理和质量研究(第 4 册)[M]. 北京: 北京医科大学、中国协和医科大学联合出版社, 2003: 123-182.
- [8] 中国科学院中国植物志编辑委员会. 中国植物志(第二十三卷第一分册)[M]. 北京: 科学出版社, 1998: 6-23.
- [9] 王龙星, 肖红斌, 梁鑫森, 等. 一种评价中药色谱指纹谱相似性的新方法: 向量夹角法[J]. 药学学报, 2002, 37(9): 713-717.
- [10] 杨文字, 万德光. 中药桑枝和桑白皮的品种、品质与药效的研究[D]. 成都: 成都中医药大学博士学位论文, 2008: 9-25.
- [11] 万德光. 中药品质研究——理论、方法与实践[M]. 上海: 上海科学技术出版社, 2008: 18-76.

(2011-10-08 收稿, 2011-10-12 修回)